



Université Abdelmalek Essaâdi

Faculté des Sciences et Techniques de Tanger

Département Génie Informatique

Master IASD



Rapport de Projet de fin de module

**Analyse Décisionnelle et Prédiction des Ventes d'un Réseau de
Distribution Multi-Magasins**

Module : DATAMING & BI

Encadré par :
Pr. Salma CHRIT

Réalisé par :
MINYURANO Aloys

Année universitaire : 2025-2026

Table des Matières

Introduction

Problématique Général

Partie I — Présentation des Données & Architecture

- 1.1 Source des données
- 1.2 Schéma en Étoile (Star Schema) ← SCHÉMA
- 1.3 Schéma en Flocon (Snowflake Schema) ← SCHÉMA
- 1.4 Comparaison Étoile vs Flocon

Partie II — Indicateurs Clés de Performance (KPIs)

- 2.1 Tableau des KPIs
- 2.2 Visualisation des KPIs ← GRAPHIQUE
- 2.3 Interprétation

Partie III — Analyse des Produits

- 3.1 Top 10 produits par CA ← GRAPHIQUE
- 3.2 Analyse par catégorie ← GRAPHIQUE
- 3.3 Interprétation

Partie IV — Analyse Temporelle

- 4.1 Ventes par semaine ← GRAPHIQUE
- 4.2 Ventes par mois ← GRAPHIQUE
- 4.3 Ventes par trimestre & semestre
- 4.4 Interprétation

Partie V — Performance Clients & Magasins

- 5.1 Analyse clients
- 5.2 Analyse magasins ← GRAPHIQUE
- 5.3 Promotions & cross-selling

Partie VI — Modèles de Prédiction ML

- 6.1 Préparation des données
- 6.2 Régression Linéaire ← GRAPHIQUE
- 6.3 Arbre de Décision ← GRAPHIQUE
- 6.4 Forêt Aléatoire (Random Forest) ← GRAPHIQUE
- 6.5 Comparaison des modèles ← TABLEAU
- 6.6 Prédictions 7 jours ← GRAPHIQUE

Conclusion & Recommandations

Bibliographie / Références

Problématique Générale

« Dans un contexte de distribution multi-magasins caractérisé par une fragmentation de la clientèle et une dépendance critique à la saisonnalité, comment l'unification d'une architecture décisionnelle (BI) et de l'apprentissage automatique (Machine Learning) permet-elle de transformer des signaux transactionnels faibles en leviers de pilotage opérationnel et de prévisibilité de la demande ? »

Introduction

Dans le contexte actuel de la transformation numérique, l'analyse des données de vente constitue un levier stratégique majeur pour toute entreprise souhaitant optimiser ses performances commerciales. Ce rapport présente une étude complète réalisée à partir d'un entrepôt de données (Data Warehouse) modélisé selon deux architectures dimensionnelles : le schéma en étoile et le schéma en flocon de neige.

L'objectif de ce travail est triple :

1. Modéliser et comparer les deux architectures de Data Warehouse (étoile et flocon) ;
2. Analyser les indicateurs de performance commerciale (KPIs, produits, clients, magasins, temporalité) ;
3. Appliquer des modèles de Machine Learning pour prédire les ventes futures.

Données	Tables FACT_VENTES + 6 dimensions (DIM_PRODUIT, DIM_CLIENT, DIM_MAGASIN, DIM_EMPLOYE, DIM_PROMOTION, DIM_DATE) + tables SNOW_DIM_*
Outils	Python (Pandas, Matplotlib, Seaborn, Plotly, Scikit-learn), Jupyter Notebook, Sql server ,Power BI
Modèles ML	Régression Linéaire, Arbre de Décision, Forêt Aléatoire (Random Forest)
Périmètre	Analyse multi-dimensionnelle des ventes : produits, clients, magasins, temps, promotions

Ce rapport est organisé en six parties : (I) présentation de l'architecture des données, (II) analyse des KPIs, (III) analyse produits, (IV) analyse temporelle, (V) performance clients et magasins, et (VI) modèles prédictifs.

Partie I — Présentation des Données & Architecture du Data Warehouse


1.1 Source et Description des Données

Le jeu de données utilisé provient d'un Data Warehouse de vente au détail. Il est composé d'une table de faits centrale et de plusieurs tables de dimensions, chacune apportant un axe d'analyse distinct.

Table	Type	Rôle
FACT_VENTES	Table de faits	Contient les transactions : montant_ttc, quantite, id_date, id_produit, id_client, id_magasin, id_employe, id_promo
DIM_PRODUIT	Dimension	Caractéristiques des produits : nom, catégorie, prix
DIM_CLIENT	Dimension	Profil client : nom, ville, segment
DIM_MAGASIN	Dimension	Localisation et type de magasin
DIM_EMPLOYE	Dimension	Employé responsable de la vente
DIM_PROMOTION	Dimension	Type et taux de promotion appliquée
DIM_DATE	Dimension	Calendrier complet : jour, semaine, mois, trimestre, année
SNOW_DIM_*	Dimension flocon	Tables normalisées : DIM_CATEGORIE, DIM_MOIS, DIM_ANNEE, DIM_SEMAINE

1.2 Schéma en Étoile (Star Schema)


Le schéma en étoile est la première architecture choisie pour ce Data Warehouse. Il place la table de faits **FACT_VENTES** au centre, directement reliée aux six tables de dimensions sans normalisation supplémentaire. Cette structure favorise des requêtes rapides et une lecture intuitive des données.



Description du schéma : La table centrale FACT_VENTES contient les clés étrangères id_date, id_produit, id_client, id_magasin, id_employe, id_promo qui pointent directement vers leurs tables de dimension respectives. Chaque dimension est plate (non normalisée), ce qui réduit le nombre de jointures nécessaires.

1.3 Schéma en Flocon de Neige (Snowflake Schema)

Le schéma en flocon étend le schéma en étoile en normalisant certaines dimensions. Ainsi, la dimension produit est décomposée en SNOW_DIM_PRODUIT → SNOW_DIM_CATEGORIE, et la dimension date en SNOW_DIM_DATE → SNOW_DIM_MOIS → SNOW_DIM_ANNEE et SNOW_DIM_SEMAINE. Cette normalisation réduit la redondance des données mais introduit des jointures supplémentaires.



1.4 Comparaison Étoile vs Flocon

Critère	Schéma Étoile	Schéma Flocon
Structure	Dimensions plates (non normalisées)	Dimensions normalisées (sous-tables)
Nombre de tables	Peu de tables (1 fait + N dim.)	Plus de tables (sous-dimensions)
Redondance données	Élevée	Faible
Vitesse des requêtes	Rapide (moins de jointures)	Plus lent (jointures multiples)
Lisibilité / Maintenance	Très lisible, simple	Plus complexe
Usage recommandé	Analyses rapides, Power BI, rapports	Entrepôts volumineux, normalisation stricte

Choix architectural



Pour ce projet, le schéma en étoile est privilégié pour les analyses rapides et les visualisations Power BI, grâce à sa simplicité de jointure. Le schéma en flocon est utilisé pour modéliser la hiérarchie temporelle (année → mois → semaine) et la hiérarchie produit (catégorie → sous-catégorie → produit), réduisant ainsi la redondance dans les dimensions les plus volumineuses.

Partie II — Indicateurs Clés de Performance (KPIs)


Cette section présente les indicateurs de performance calculés à partir de la table de faits FACT_VENTES fusionnée avec ses dimensions. Ces KPIs constituent le tableau de bord de haut niveau permettant d'évaluer la santé commerciale globale.

2.1 Tableau des KPIs Globaux

Le tableau suivant synthétise les dix indicateurs principaux extraits du notebook. Les valeurs réelles produites par votre script doivent remplacer les espaces réservés ci-dessous.

Indicateur	Valeur obtenue
Chiffre d'Affaires Total (€)	126 €
Nombre de Transactions	20
Panier Moyen (€)	6.31 €
Quantité Totale Vendue	63
Nombre de Clients Uniques	10
Nombre de Produits Uniques	12
Nombre de Magasins	

2.2 Visualisation des KPIs



2.3 Interprétation des KPIs

Lecture du CA Total

- ✓ Le CA total s'élève à 126€, ce qui représente un volume d'affaires [élevé / modéré] sur la période étudiée. »

Lecture du Panier Moyen

- ✓ Le panier moyen de 6,31 € indique que les clients achètent en moyenne **petits achats fréquents**. En effet, ce montant modeste, associé à une quantité vendue totale de 63 unités pour 20 transactions (soit environ 3,15 articles par ticket), confirme des dépenses limitées à chaque passage. Toutefois, le profil de la clientèle est qualifié de sporadique et occasionnelle (100 % du CA provient d'acheteurs à faible budget, segment < 30 €), ce qui nuance la notion de fréquence : les passages sont rares, mais lorsqu'ils ont lieu, ils portent sur de petites dépenses.

Dispersion des ventes (Écart-Type)

- ✓ Un écart-type faible par rapport au panier moyen révèle une relative homogénéité dans les montants des transactions, suggérant un comportement d'achat homogène. En effet, l'analyse montre que 100 % du chiffre d'affaires provient d'acheteurs occasionnels à faible budget (segment < 30 €), avec un panier moyen global de 6,31 € et une productivité moyenne par client située entre 11,90 € et 14,20 € selon les


viles. Cette concentration des dépenses sur une fourchette resserrée indique que les écarts entre transactions sont limités, renforçant l'idée d'une clientèle aux habitudes d'achat peu différenciées, malgré une fréquentation sporadique.

Partie III — Analyse des Produits

L'analyse des produits vise à identifier les best-sellers, les catégories les plus rentables et les leviers d'optimisation de l'assortiment.

3.1 Top 10 Produits par Chiffre d'Affaires

Le classement suivant est issu de l'agrégation de la table fusionnée par nom_produit, trié par montant_ttc décroissant. Pour chaque produit, le nombre de ventes, la quantité totale et la part du CA global ont été calculés.




Le chiffre d'affaires est dominé par les produits à forte valeur unitaire comme le **Coca-Cola 2L** (leader incontesté), tandis que les volumes les plus élevés concernent les produits de base et d'usage quotidien (**Pâtes 500g** en tête).

Cela révèle une stratégie de rentabilité par le prix sur les boissons et une rotation rapide des volumes sur les aliments essentiels.

3.2 Analyse par Catégorie de Produits

La répartition par catégorie permet d'identifier les familles de produits contribuant le plus au chiffre d'affaires global.



3.3 Interprétation — Analyse Produits

Produit leader

- ✓ Le produit le plus performant en CA est boissons, représentant 38.6% du CA total. Cela indique une forte concentration des revenus sur un nombre limité de références (loi de Pareto / règle 80-20).

Catégorie dominante

- ✓ La catégorie des boissons concentre 50% du chiffre d'affaires. Cette prédominance suggère une orientation marquée de la demande / une stratégie commerciale centrée sur cette famille de produits.


Produits à faible performance

- ✓ Le produit en queue de classement est Epicerie sèche nécessite une évaluation de leur maintien dans l'assortiment. Une analyse coût/bénéfice permettrait de décider de leur éventuel retrait ou repositionnement.

Partie IV — Analyse Temporelle des Ventes

L'analyse temporelle permet d'identifier les saisonnalités, les pics d'activité et les tendances sur différentes granularités : semaine, mois, trimestre et semestre.

4.1 Analyse par Semaine




L'évolution du chiffre d'affaires hebdomadaire révèle une forte **saisonnalité** avec un pic exceptionnel en S1-2024 (25,5 €), suivi d'une période de faible activité jusqu'à mi-année, puis une reprise marquée en fin d'année (pics à 14 € en S37 et 16,5 € en S52).

Cette tendance suggère une concentration des ventes en début et fin d'année, probablement liée à des événements promotionnels, fêtes ou comportements d'achat saisonniers, tandis que les semaines intermédiaires affichent une activité plus faible et irrégulière.

4.2 Analyse par Mois

L'agrégation mensuelle révèle les patterns saisonniers sur l'ensemble de la période étudiée. Le tableau ci-dessous résume les principaux indicateurs mensuels (CA Total, CA Moyen, Écart-Type, Nombre de Ventes, Quantité).




L'évolution mensuelle montre une forte **saisonnalité** du chiffre d'affaires, avec un creux prononcé en juillet (environ 4 €) et un pic exceptionnel en décembre (plus de 31 €), indiquant une concentration des ventes en fin d'année.

Le nombre de ventes suit une tendance similaire, culminant à 4 transactions en décembre et 3 en janvier, ce qui révèle une activité plus intense durant les périodes de fêtes et de début d'année, tandis que les mois intermédiaires affichent une faible rotation.


4.3 Analyse par Trimestre & Semestre

La granularité trimestrielle et semestrielle permet d'avoir une vision macro des performances et de comparer les grandes périodes de l'année.



Le chiffre d'affaires trimestriel révèle une très forte **saisonnalité**, avec un quatrième trimestre largement dominant (52 €, soit 41,3 % du CA annuel), tandis que les trois premiers trimestres affichent des performances plus modérées et relativement stables (entre 22 et 27 €).


Cette répartition confirme une concentration marquée des ventes en fin d'année, probablement liée aux fêtes de fin d'année, et souligne une dépendance importante de l'activité au dernier trimestre.



Le chiffre d'affaires est nettement plus élevé au **second semestre** (77 €, soit 61,2 % du total annuel) qu'au premier semestre (49 €, 38,8 %), révélant une forte **saisonnalité** intra-annuelle.

Cette répartition confirme une accélération significative de l'activité commerciale après juin, probablement liée aux promotions de rentrée, aux fêtes de fin d'année et à une consommation plus soutenue en S2.


4.4. Analyse par Année



Le chiffre d'affaires total de l'année 2024 s'élève à **124 €**, représentant la performance annuelle globale de l'activité.

Avec un seul point de données disponible sur le graphique d'évolution, aucune tendance pluriannuelle ne peut être observée ; 2024 constitue donc l'année de référence unique pour l'analyse.

4.5. Analyse par jour de semaine




Partie V — Performance Clients, Magasins & Promotions

5.1 Analyse des Clients

L'analyse des clients permet d'identifier les segments les plus rentables et les clients à fort potentiel (clients VIP). La segmentation s'appuie sur le CA généré par client.

Top Clients par CA (barres horizontales)



Client le plus performant


L'intégralité du chiffre d'affaires (100 %) provient du segment **Occasionnel Moins de 30 Euros**, confirmant que la clientèle est exclusivement composée d'acheteurs ponctuels à faible budget.

- ✓ Parmi les top 5 clients, **Awa Diallo** se distingue nettement avec une dépense totale d'environ 24 €, suivie par Seydou Camara (16 €), tandis que les autres clients restent en dessous de 15 €, illustrant une concentration faible et une base client très fragmentée.

5.2 Analyse des performances par ville

PERFORMANCE PAR VILLE					

Utilisation de la colonne: ville_x					
	CA_Total	Quantite_Totale	Nb_Magasins	Nb_Clients	CA_par_Client
ville_x					
Dakar	47.62	22	3	4	11.90
Abidjan	42.60	23	3	3	14.20
Bamako	36.05	18	4	3	12.02



Dakar domine avec le **chiffre d'affaires total** le plus élevé (47,62 €), grâce à un nombre important de clients et un bon volume de ventes, malgré un CA par client légèrement inférieur à Abidjan.

Abidjan se distingue par le **panier moyen par client** le plus élevé (14,20 €) et un volume total comparable, tandis que **Bamako** affiche les performances les plus faibles en CA total, malgré le plus grand nombre de magasins (4), révélant une productivité moindre par point de vente.


5.3 Impact des Promotions & Cross-Selling

L'analyse de l'impact promotionnel compare les ventes réalisées avec et sans promotion. Le cross-selling identifie les combinaisons de produits fréquemment achetés ensemble.

ANALYSE DES PROMOTIONS

COMPARAISON AVEC ET SANS PROMOTION

PERFORMANCE PAR TYPE DE PROMOTION




Les ventes **sans promotion** affichent une performance supérieure avec un **CA total** plus élevé (68 € contre 59 €) et un **panier moyen** meilleur (6,8 € contre 5,9 €), pour un même nombre de transactions (10).

Les promotions ont un impact négatif clair : elles réduisent la quantité vendue (25 contre 37 unités) et la valeur globale, suggérant une possible cannibalisation ou une baisse de la perception de valeur chez les clients.

MATRICE ABC - LOI DE PARETO 80/20

CLASSIFICATION DES PRODUITS

STATISTIQUES PAR CATEGORIE ABC




La courbe de Pareto révèle une **forte concentration** du chiffre d'affaires : le premier produit génère à lui seul plus de 23 €, tandis que les **4 premiers produits** représentent déjà environ 80 % du CA total.

Cette distribution classique illustre le principe 80/20 : une minorité de produits (les best-sellers) tire l'essentiel des revenus, tandis que les produits suivants contribuent très marginalement, suggérant de concentrer les efforts commerciaux et de gestion de stocks sur ce noyau vital.

ANALYSE DES EMPLOYES

Utilisation de la colonne magasin: nom_magasin_x

TOP 10 EMPLOYES PAR CA REALISE




Luc Moreau domine le classement avec **24 €** de CA réalisé, suivi de près par **Jean Dupont** (23 €) et **Paul Martin** (22 €), montrant une forte contribution des trois meilleurs vendeurs. Les performances restent cependant très concentrées sur le top 3, tandis que **Marie Lefebvre** affiche un écart significatif (12 €), révélant une inégalité notable dans la productivité commerciale des employés.

ANALYSE DES CORRELATIONS ET INSIGHTS PROFESSIONNELS

1. MATRICE DE CORRELATION

Matrice de corrélation entre les variables numériques:



La matrice révèle une **forte corrélation positive** entre les montants HT et TTC (0.989), ainsi qu'une relation modérée entre la quantité vendue et les montants facturés (0.42 à 0.46).

On observe également une **corrélation négative significative** entre le prix unitaire et la quantité (-0.551), confirmant l'effet classique prix/volume, tandis que le taux de remise montre une influence globalement faible sur les autres variables.


2. ANALYSE DES PRODUITS SOUVENT ACHETES ENSEMBLE (CROSS-SELLING)

Aucune combinaison de produits trouvee

3. MEILLEURES COMBINAISONS MAGASIN-PRODUIT

TOP 10 COMBINAISONS MAGASIN-PRODUIT PAR CA:

- Supermarche A - Sud - Essuie-tout x4: 13.80 Euros
- Supermarche A - Sud - Coca-Cola 2L: 12.60 Euros
- Supermarche A - Nord - Coca-Cola 2L: 11.20 Euros
- Supermarche A - Nord - Pates 500g: 11.05 Euros
- Supermarche A - Sud - Jus d orange 1L: 10.50 Euros
- Supermarche A - Centre - Lessive liquide 3L: 8.68 Euros
- Supermarche A - Est - Dentifrice 75ml: 7.50 Euros
- Supermarche A - Nord - Eau minerale 6x1.5L: 7.35 Euros
- Supermarche A - Centre - Eau minerale 6x1.5L: 7.06 Euros
- Supermarche A - Centre - Lait entier 1L: 6.66 Euros




Les meilleures performances sont largement dominées par le magasin **Supermarché A - Sud**, qui occupe les deux premières positions avec l'**Essuie-tout x4** (14 €) et le **Coca-Cola 2L** (environ 13 €), suivi de près par le magasin **Nord**.

Cette concentration révèle que la combinaison **magasin Sud + produits à forte rotation ou valeur unitaire élevée** (boissons et produits d'entretien) constitue le principal moteur du chiffre d'affaires, soulignant l'importance stratégique de ces emplacements et références.

4. ANALYSE DU PANIER MOYEN PAR CATEGORIE

Panier moyen par categorie de produits:



Le **panier moyen** est nettement plus élevé dans les catégories **Entretien Maison** (9,56 €) et **Boissons** (8,12 €), révélant que ces produits génèrent une dépense unitaire supérieure. À l'inverse, les catégories **Alimentation** (3,73 €) et **Épicerie Sèche** (4,97 €) affichent les paniers les plus faibles, confirmant une stratégie volume/prix sur les produits de base et une rentabilité plus forte sur les articles d'entretien et boissons.

5. INSIGHTS STRATEGIQUES ET RECOMMANDATIONS

=====

IMPACT PROMOTIONS:

- Les promotions generent -13.4% de CA supplementaire

PERFORMANCE TEMPORELLE:

- Meilleur jour de vente: Tuesday

PERFORMANCE MAGASINS:

- Meilleur magasin: Supermarche A - Sud

PERFORMANCE CLIENTS:

- Meilleur client: Awa Diallo (23.72 Euros)

Partie VI — Modèles de Prédiction par Machine Learning

Conclusion & Recommandations Stratégiques

Synthèse des résultats

Ce rapport a permis d'analyser de manière complète et structurée les données de ventes d'un Data Warehouse modélisé selon deux architectures complémentaires : le schéma en étoile et le schéma en flocon. Les principaux enseignements sont les suivants :

Architecture DW	Le schéma en étoile offre la meilleure performance analytique pour des requêtes OLAP. Le schéma en flocon réduit la redondance dans les dimensions hiérarchiques (date, produit).
KPIs globaux	Le CA total de 124 € sur l'année 2024 confirme un volume d'activité modéré. Le panier moyen d'environ 6 € oriente la stratégie tarifaire vers un mix volume/prix.
Produits	Les 20% meilleurs produits génèrent ~80% du CA (loi de Pareto). La catégorie Boissons domine avec 39,4% du CA récent, suivie par l'Entretien Maison.
Temporalité	Le quatrième trimestre et le mois de décembre sont les périodes de pic. Des actions promotionnelles ciblées sur ces fenêtres optimiseraient les revenus.
Clients & Magasins	La clientèle est majoritairement occasionnelle (moins de 30 €). Le magasin Sud est le benchmark de performance avec le CA le plus élevé et le meilleur panier moyen.
Prédiction ML	Le modèle Arbre de Décision ($R^2 \approx 0,78$) prédit les ventes avec une précision satisfaisante. Les prévisions sur 7 jours estiment un CA moyen de 12,2 € par jour.

Recommandations Stratégiques

Sur la base de l'ensemble des analyses, les recommandations suivantes sont formulées :

1. Concentrer les efforts marketing sur les produits et catégories à fort CA, tout en évaluant la rentabilité des produits en queue de peloton.
2. Renforcer les effectifs et les stocks lors des pics identifiés (meilleur jour, meilleur mois, meilleur trimestre).
3. Mettre en place un programme de fidélisation pour les clients VIP du top 10 (remises personnalisées, accès prioritaire aux promotions).
4. Implémenter le modèle [X] en production pour anticiper les besoins de stock et optimiser la gestion des approvisionnements.
5. Développer une stratégie de cross-selling basée sur les combinaisons produits identifiées, via des recommandations en caisse ou en ligne.
6. Étudier les pratiques du magasin le plus performant et les répliquer dans les points de vente sous-performants.

Perspectives & Améliorations Futures

- Intégrer des données externes (météo, événements locaux, jours fériés) pour améliorer la précision des modèles ML.
- Tester des modèles avancés : LSTM (réseau de neurones temporel), Prophet (Meta/Facebook), XGBoost.
- Construire un tableau de bord Power BI interactif connecté directement au Data Warehouse pour un suivi en temps réel.
- Étendre l'analyse à la segmentation client RFM (Récence, Fréquence, Montant) pour un ciblage marketing plus fin.

Bibliographie & Références

Outils et Bibliothèques Utilisés

- Python 3.x — Langage de programmation principal
- Pandas — Manipulation et agrégation des données
- Matplotlib & Seaborn — Visualisations statistiques
- Plotly — Graphiques interactifs
- Scikit-learn — Modèles de Machine Learning (LinearRegression, DecisionTreeRegressor, RandomForestRegressor)

Références Méthodologiques

- Kimball, R. & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling. Wiley.
- Inmon, W.H. (2005). Building the Data Warehouse. Wiley.
- Hastie, T., Tibshirani, R. & Friedman, J. (2009). The Elements of Statistical Learning. Springer.
- Breiman, L. (2001). Random Forests. Machine Learning, 45, 5–32.